

Pulse 109

Техническое задание и архитектура платформы

Версия 1.1 для согласования с государственным заказчиком

GovTech Camp 2026 Кейс интеллектуальной платформы работы с обращениями граждан

Параметр	Значение
Команда	baash
Дата	11 сентября 2026 года
Статус	Проект технического задания
Горизонт	Production grade pilot за 1 месяц Целевая национальная архитектура
Ограничение	Не более двух GPU

Документ определяет целевую систему и проверяемый объём первого внедрения. Пункты с пометкой TBD требуют письменного решения владельца процесса до промышленного запуска.

Управление документом

Назначение. Этот документ служит общей основой для product, frontend, backend, data, ML, DevOps, QA, информационной безопасности и интеграционных команд. Он фиксирует границы платформы, интерфейсы и критерии приёмки, чтобы отдельные части можно было развивать без пересборки всей архитектуры.

Версия	Дата	Изменение	Статус
1.1	11.09.2026	Зафиксирован модельный стек пилота и обновлён технический пакет	На согласование

Правила обязательности

Метка	Смысл	Как принимается
P0	Обязательное требование первого production grade pilot	Должно пройти автоматическую или сценарную проверку
P1	Нужная функция после стабилизации P0	Планируется и принимается отдельным тестом
P2	Расширение после получения данных и интеграций	Не блокирует первый пилот
TBD	Решение отсутствует у команды и должно прийти от заказчика	До ответа действует явно указанное безопасное допущение

При конфликте требований приоритет имеют закон, утверждённые политики безопасности и письменное решение владельца процесса. Изменение API, канонической схемы или правил SLA оформляется версией контракта и записью в журнале архитектурных решений.

Ключевое решение

За один месяц реально выпустить production grade pilot с надёжным критическим путём, одним интеграционным адаптером и воспроизводимыми моделями. Полное промышленное покрытие 20 регионов нельзя считать завершённым до получения данных остальных 13 регионов, исходного текста обращений, SLA правил, API и целевой инфраструктуры. Архитектура ниже поддерживает этот масштаб, но критерии первого релиза не подменяют отсутствующие зависимости симуляцией.

Содержание

- 1 Назначение и границы платформы

2 Основания и текущее состояние

3 Пользователи и рабочие сценарии

4 Контекст и архитектурные принципы

5 Функциональные требования

6 Архитектура приложений

7 Архитектура данных

8 Архитектура машинного обучения

9 API и интеграции

10 Безопасность и персональные данные

11 Инфраструктура и развёртывание

12 Производительность и надёжность

13 Наблюдаемость и эксплуатация

14 Тестирование и приёмка

15 План реализации на один месяц

16 Сопровождение и развитие

17 Риски и решения

18 Вопросы заказчику

19 Итоговые критерии готовности

Приложения

1 Назначение и границы платформы

1.1 Цель

Pulse 109 должен принимать обращения из разных каналов и региональных систем, помогать оператору принять проверяемое решение, связывать повторные сообщения в управляемые инциденты и давать руководителю своевременную аналитику. Система сокращает ручной поиск и перенос данных, но не принимает высокорисковые решения вместо человека.

Цель	Измеритель	Порядок доказательства
Сократить ручной разбор	АНТ и время до назначения	Shadow сравнение с действующим процессом
Снизить ошибки маршрутизации	Доля переназначений и их причины	История from service to service
Ускорить поиск решения	Время поиска и accept rate кандидатов	Операторская оценка judged set
Раньше выявлять массовые проблемы	Precision алертов и time to detect	Backtest и журнал подтверждений
Унифицировать аналитику	Совпадение экранов и экспортов	Один semantic layer и reconciliation test

1.2 Объём целевой платформы

- Смарт приём, двуязычная классификация минимум по десяти темам, подсказка службы и приоритета.
- Рабочее место оператора с похожими случаями, кандидатами дубликатов, черновиком ответа и фиксацией исправлений.
- Граф городских инцидентов, где несколько обращений сохраняют собственные номера и SLA, но исполняются как одна проблема.
- Ситуационный центр по регионам, темам, каналам, SLA, всплескам и прогнозу нагрузки на один три месяца.
- Версионизируемая таксономия, каталог служб, правила SLA и административные функции.
- Интеграционные адаптеры, канонический контракт, импорт файлов, двусторонняя синхронизация статусов и вложений.
- Контур ML lifecycle, мониторинг, аудит, резервное копирование и эксплуатационная документация.

1.3 Вне объёма первого релиза

Не входит	Причина	Интерфейс на будущее
Замена телефонии и IVR	Требует отдельной закупки и интеграции	Channel adapter и transcript reference
Замена региональных CRM	Существующие ИС остаются системами исполнения	Regional adapter contract
Полностью автономное назначение	Нет подтверждённых правил и достаточной валидации	Policy engine с human gate
Свободный SQL от LLM	Риск утечки и неверных чисел	Metric ID и проверенный AST
Национальный запуск без пилота	Нет данных и API всех регионов	Adapter kit и onboarding checklist

1 4 Два уровня готовности

Уровень	Результат	Обязательное доказательство
Релиз за месяц	Production grade pilot в тестовом или ведомственном контуре с одним реальным адаптером и mock второго	E2E сценарий, security и load тесты, rollback, runbooks, измеренные ML метрики
Целевая эксплуатация	Покрытие 20 регионов и утверждённые интеграции	Данные 20 регионов, SLO владельца, полный DPIA, DR тест, поддержка и on call

2 Основания и текущее состояние

2 1 Обязательные требования кейса

Источник	Подтверждённое требование	Влияние на проект
T3 GovTech Camp	Три модуля в одном сценарии; 20 регионов; казахский и русский; отчёты PDF и Excel	Платформа и демо проектируются сквозным контуром
T3 GovTech Camp	Fine tuned classifier и fine tuned embedding; prompt only не засчитывается	Нужны checkpoints, training logs и held out оценка
T3 GovTech Camp	Human in the loop, приватность, объяснимость, воспроизводимый код	AI остаётся советующим слоем с аудитом
Вебинар	Архитектура согласуется на второй неделе; внедрение и интеграции идут после отбора	Контракты и вопросы заказчику блокируют архитектуру

2 2 Фактический профиль данных

EDA охватил 12 файлов: 1 063 216 физических строк, 1 036 858 строк в канонических CSV и 990 032 записи после дедупликации по идентификаторам. Доступны выгрузки семи регионов. CSV и XLSX часто представляют одни и те же данные на разных уровнях детализации, поэтому они не складываются без provenance и проверки пересечения.

Наблюдение	Факт	Требование к системе
Неполное покрытие	7 из 20 регионов	Показывать coverage и не подставлять синтетические регионы как реальные
Сильный дисбаланс	Павлодар 67,3 процента dedup объёма	Macro F1, per region metrics и balanced sampling
Повторные snapshots	Туркестан 98 876 строк и 52 050 уникальных incident IDs	Отделить appeal snapshot от lifecycle events
Повреждённые записи	Akmola 32 сдвига колонок и дат; 37 canonical records без валидной даты	Quarantine и time quality вместо фиктивной даты
Schema drift	Алматы смешивает статусы, каналы и поля	Версия source schema и contract tests
Нет исходного текста	В большинстве выгрузок только решения и статусы	Отдельный запрос raw text; запрет post event leakage

2 3 Блокирующие зависимости

Зависимость	Что блокирует	Безопасный режим до ответа
Raw text или транскрипт	Обязательное обучение classifier и embedding	Демо на честно размеченном ограниченном наборе; статус ограничения виден
История переназначений	Misroute label и обучение маршрутизации	Service taxonomy как weak label; ручной test set
Связи дубликатов	Обучение и cluster evaluation	Высокоточные кандидаты и только ручное подтверждение
Правила SLA и опасных тем	Priority и due date	Rule engine работает только с утверждёнными временными правилами
API первой региональной ИС	Реальная двусторонняя интеграция	Mock adapter с тем же контрактом и replay fixtures
Целевой контур и GPU	Capacity и security sign off	Docker deployment и CPU fallback benchmark

3 Пользователи и рабочие сценарии

3 1 Роли

Роль	Основная задача	Разрешённые действия	Запрещено по умолчанию
Гражданин	Подать и отслеживать обращение	Создать, дополнить, получить статус, оценить результат, геореп по правилу	Видеть другие обращения и внутренние заметки
Оператор	Понять запрос и оформить карточку	Редактировать intake, выбрать тему и службу, подтвердить подсказку	Менять справочники и системные SLA
Супервайзер	Контролировать качество смены	Переназначать, подтверждать incident, разбирать dead letters	Менять модель без approval
Исполнитель	Принять и исполнить задачу	Менять разрешённые статусы, прикладывать результат	Читать PII вне назначенных задач
Аналитик	Считать утверждённые показатели	Query semantic layer, экспортировать обезличенные срезы	Произвольный доступ к raw PII
Руководитель	Принимать операционные решения	Просматривать агрегаты, алерты, прогнозы и provenance	Редактировать историю обращений
Data steward	Контролировать качество и mapping	Управлять схемами, quarantine и ontology mapping	Продвигать модели
ML owner	Обучать и выпускать модели	Регистрировать candidate, запускать evaluation и shadow	Самостоятельно обходить security approval
Администратор	Управлять доступом и настройками	RBAC, интеграции, секреты по разделению обязанностей	Читать содержимое обращений без основания
Аудитор	Проверять решения и доступ	Read only audit, model and policy history	Изменять operational state

3 2 Сквозной сценарий оператора

1. Канал или региональная ИС создаёт обращение с idempotency key. Платформа сохраняет raw reference, provenance и минимальную карточку до вызова ML.
2. Privacy pipeline отделяет прямые идентификаторы и формирует отредактированный текст. Адрес нормализуется до geo ID и объекта с указанием точности.
3. Classifier показывает top 3 тем и служб, confidence, OOD, rule hits и одно уточнение только при влиянии на маршрут.
4. Оператор принимает, исправляет или выбирает вручную. Причина исправления становится частью audit и будущей разметки.
5. Retrieval показывает похожие решения, а incident service предлагает дубликаты по тексту, месту, времени и службе.
6. После подтверждения core сохраняет решение и outbox запись одной транзакцией. Adapter доставляет назначение с retry и external ID.
7. Статусы и результат возвращаются как события. Гражданин получает собственную timeline даже внутри общего incident.

3 3 Альтернативные сценарии

Ситуация	Обязательное поведение	Пользовательский результат
ML недоступен	Не блокировать создание; открыть каталог и записать inference failure	Оператор завершает приём вручную
Низкая уверенность	Top 3 и targeted question; запрет auto assignment	Неопределённость видима
Опасное обращение	Rule engine повышает уровень и показывает утверждённую инструкцию	Модель не может понизить приоритет
Внешняя ИС недоступна	Сохранить локальное решение, outbox retry, явный sync status	Обращение не теряется
Предлагается дубликат	Сохранить отдельный request ID; связь подтверждает человек	Гражданин сохраняет права и уведомления
Нет точной даты	Хранить null и quality flag; использовать observed time отдельно	Нет выдуманной точности
Нет результата для черновика	Не генерировать ответ; запросить evidence	Нет уверенной формальной отписки

4 Контекст и архитектурные принципы

Контекст Pulse 109




Рисунок 1 Контекст системы и внешние границы

4 1 Архитектурные принципы

Принцип	Обязательное следствие
Contract first	UI, core, ML и adapters зависят от версионизируемых схем, а не от колонок конкретного экспорта
Human controlled AI	Предложение, уверенность, подтверждение и исправление сохраняются раздельно
Critical path first	Приём и ручное назначение работают без LLM, retrieval, analytics и внешней ИС
Privacy by design	PII отделяется до feature store; экспорт и ML получают минимальные поля
Temporal truth	Occurred time, observed time, timezone и качество времени не смешиваются
Append only history	Статус и переназначение фиксируются событиями; текущая карточка является snapshot
Measure before split	Новый физический сервис или БД появляются после доказанного bottleneck или отдельного ownership
Open source with exit	Каждый компонент имеет экспорт данных, резервную реализацию и проверенную лицензию

4 2 Основные архитектурные решения

Решение	Выбор	Условие пересмотра
Бизнес ядро	Модульный монолит FastAPI	Разный ownership или отдельный scaling bottleneck
Операционная БД	PostgreSQL с отдельными schema по модулям	Измеренная необходимость шардирования
Гео и vector	PostGIS и pgvector HNSW	P95 или recall не проходят benchmark на реальных фильтрах
События	Transactional outbox и worker	Несколько независимых потребителей и долговременный высокий поток
ML serving	ONNX Runtime; Triton только после benchmark	Несколько GPU моделей требуют dynamic batching
Хранилище файлов	S3 compatible object storage	Политика заказчика требует иной совместимый объектный API
Deployment	Одинаковые контейнеры для Docker Compose и Helm	Целевой контур фиксирует OpenShift или QazTech profile

5 Функциональные требования

Каждое P0 требование должно иметь тест, владельца и ссылку на evidence. Приёмка по скриншоту без воспроизводимого теста не засчитывается.

5 1 Смарт приём

ID	Приоритет	Требование	Критерий приёмки
FR-IN-001	P0	Принимать обращения через внутренний REST API и импорт регионального адаптера.	POST создаёт один request при повторе idempotency key.
FR-IN-002	P0	Поддерживать каналы phone, web, mobile, Telegram, WhatsApp, email, walk in и import.	Канал хранится как canonical value и source code.
FR-IN-003	P0	Поддерживать русский, казахский, mixed и unknown.	Язык виден оператору и входит в slice metrics.
FR-IN-004	P0	Сохранять received at, observed at, source timezone и time quality.	Запись без даты принимается с null и quality missing.
FR-IN-005	P0	Разделять PII и отредактированный текст до ML.	Прямые идентификаторы отсутствуют в inference request и logs.
FR-IN-006	P0	Нормализовать адрес до geo ID или показать ambiguity.	Тест покрывает exact approximate ambiguous missing.
FR-IN-007	P0	Показать top 3 тем и служб, priority assist, confidence и OOD.	Ответ содержит версии модели и таксономии.
FR-IN-008	P0	Применять утверждённые safety rules поверх модели.	Правило может повысить уровень; модель не понижает его.
FR-IN-009	P1	Задавать одно уточнение, если поле меняет маршрут.	Каждый вопрос связан с missing field и policy version.
FR-IN-010	P0	Работать при отказе ML.	Оператор сохраняет и назначает обращение вручную.

5 2 Помощник оператора

ID	Приоритет	Требование	Критерий приёмки
FR-OP-001	P0	Показывать единую карточку и lifecycle timeline.	Каждый статус имеет source и observed at.
FR-OP-002	P0	Искать похожие закрытые обращения с фильтрами region topic service status.	Ответ возвращается с score и evidence reference.
FR-OP-003	P0	Использовать fine tuned multilingual embedding model.	Registry содержит base model, training manifest и held out metrics.
FR-OP-004	P0	Показывать кандидаты дубликатов с текстовыми, гео и временными основаниями.	Ни один кандидат не связывается без human decision.
FR-OP-005	P0	Сохранять accept corrected manual и correction reason.	Feedback event связан с prediction и request version.
FR-OP-006	P1	Предлагать черновик ответа только из подтверждённого результата и базы знаний.	Каждое утверждение имеет evidence ref; отправляет оператор.
FR-OP-007	P0	Запрещать черновик при отсутствии подтверждённых фактов.	UI показывает причину и нужное evidence.
FR-OP-008	P0	Поддерживать reassign и reopen с причиной.	История сохраняет from service, to service, time и actor.
FR-OP-009	P1	Поддерживать keyboard first работу и автосохранение.	Основной сценарий проходит без мыши; незавершённый ввод восстанавливается.

5 3 Граф инцидентов

ID	Приоритет	Требование	Критерий приёмки
FR-IC-001	P0	Создавать proposed incident из двух и более обращений.	Все member requests сохраняют исходные номера.
FR-IC-002	P0	Хранить centroid, geo window, time window, topic, service и member count.	Поля версионизируются при изменении состава.
FR-IC-003	P0	Требовать подтверждение или отклонение membership.	Audit содержит actor, score, reasons и decision.
FR-IC-004	P0	Не переносить SLA одного обращения на другое автоматически.	У каждого request собственный SLA ledger.
FR-IC-005	P1	Синхронизировать подтверждённый incident во внешнюю ИС при поддержке.	Adapter capability объявляет incident support.
FR-IC-006	P0	Использовать отклонённые пары как hard negatives после review.	Training view включает только approved feedback.

5 4 Ситуационный центр

ID	Приоритет	Требование	Критерий приёмки
FR-SC-001	P0	Показывать coverage регионов, freshness и качество данных.	Регион без данных имеет по data, а не нулевые значения.
FR-SC-002	P0	Показывать динамику тем, каналов, статусов, SLA и переназначений.	Каждая визуализация связана с Metric ID.
FR-SC-003	P0	Выявлять статистические всплески и incident growth.	Alert хранит baseline, observed, confidence и version.
FR-SC-004	P0	Ограничивать новые operational alerts согласованным бюджетом.	Default не более пяти новых сигналов за смену; TBD owner.
FR-SC-005	P0	Прогнозировать объём на один три месяца с P50 и P90.	Backtest сравнивает seasonal naive и candidate.
FR-SC-006	P0	Отвечать на natural language вопрос через allowlisted semantic layer.	Результат содержит Metric ID, filters, period, data cutoff и rows.
FR-SC-007	P0	Не разрешать LLM прямой SQL и вычисление чисел.	Policy test отклоняет произвольную таблицу или поле.
FR-SC-008	P0	Экспортировать PDF и XLSX из того же metric result.	Reconciliation test даёт одинаковые значения.
FR-SC-009	P1	Поддерживать acknowledgement и resolution алерта.	Сохраняются actor, note, reason и evidence.

5 5 Администрирование

ID	Приоритет	Требование	Критерий приёмки
FR-AD-001	P0	Версионировать topic taxonomy и mapping регионов.	Запрос effective at возвращает исторически верную версию.
FR-AD-002	P0	Версионировать service catalog и required fields.	Изменение не переписывает старые decisions.
FR-AD-003	P0	Управлять policy SLA только через approval workflow.	Каждая публикация имеет автора, reviewer и effective from.
FR-AD-004	P0	Показывать schema drift и quarantined rows.	Data steward видит sample, source and error code.
FR-AD-005	P0	Управлять RBAC и region scopes через approved identity groups.	Access matrix тестируется на каждой роли.
FR-AD-006	P0	Показывать model registry aliases champion challenger rollback.	Promotion требует metrics evidence и approval ID.
FR-AD-007	P1	Поддерживать locale kk KZ и ru KZ в UI и экспортах.	Localization test не допускает смещения языков в одном template.


5 6 Интеграции

ID	Приоритет	Требование	Критерий приёмки
FR-IT-001	P0	Изолировать источник отдельным adapter package и mapping version.	Source fixture проходит contract suite.

ID	Приоритет	Требование	Критерий приёмки
FR-IT-002	P0	Поддерживать REST SOAP events SFTP или polling без изменения core.	Transport меняется adapter configuration.
FR-IT-003	P0	Сохранять source payload reference и source codes.	Канонизация обратима для audit и reprocessing.
FR-IT-004	P0	Доставлять writes at least once с idempotency.	Повтор одного event не создаёт второй external object.
FR-IT-005	P0	Выводить permanent failures в dead letter workflow.	Ошибка видима supervisor и имеет replay после исправления.
FR-IT-006	P0	Измерять adapter lag, success rate и last checkpoint.	Метрики и alert доступны operations.
FR-IT-007	P1	Предусмотреть Smart Bridge или eGov gateway profile после подтверждения.	Auth, network and rate limit оформлены отдельным deployment profile.

6 Архитектура приложений

Контейнеры и зависимости



Синхронно: intake, карточка, решение, каталог. Асинхронно: интеграция, отчёты, embeddings, прогноз, алерты.

Рисунок 2 Контейнеры целевого решения

6 1 Физические процессы первого релиза

Процесс	Ответственность	Масштабирование	Отказ
web	Next.js operator, situation and admin UI	Горизонтально stateless	API остаётся доступен другим клиентам
core api	Appeals, decisions, incidents, catalog, audit, report orchestration	Горизонтально; shared PostgreSQL	Критический outage
worker	Outbox, reports, scheduled analytics, notifications	По типам очередей	Задержка async функций
ml inference	Classifier, embedding, reranker, optional draft	GPU replica или CPU fallback	Ручной intake и lexical search
adapter runtime	Source specific protocol and mapping	По source и partition	Outbox retry; локальный state сохранён
ml training	Offline datasets, tuning, evaluation	Batch job; не в critical path	Production serving не затронут

6 2 Модули бизнес ядра

Модуль	Владеет	Публичный интерфейс	Не делает
Appeals	request snapshot и lifecycle ledger	create get append status	Не вызывает ML внутри транзакции
Triage	recommendation link и human decision	classify command record decision	Не меняет policy
Catalog	topic service SLA versions	effective catalog	Не переписывает историю
Incidents	incident и membership decisions	propose confirm add member	Не удаляет appeals
Analytics	metric definitions and query plans	governed query	Не исполняет arbitrary SQL
Reports	template and job metadata	create and fetch job	Не имеет отдельной логики метрик
Audit	security and decision trail	append internal read by auditor	Не хранит raw PII в логах
Integration	outbox state and adapter registry	deliver replay status	Не знает UI semantics

6 3 Синхронные и асинхронные границы

Операция	Режим	Timeout	Fallback
Создание обращения	Синхронно	500 ms p95 target	Нет внешних вызовов
Classifier	Синхронно с short timeout	700 ms p95 target	Manual catalog; retry async
Similar retrieval	Синхронно	1 s p95 target	PostgreSQL full text and filters
External assignment	Асинхронно	Adapter specific	Outbox retry and visible pending state
Report export	Асинхронно	60 s target	Job remains retryable
Forecast and alerts	Scheduled async	By batch window	Last approved result with timestamp
Draft generation	Optional async or bounded sync	5 s UI budget	Template only or disabled

Жизненный цикл обращения

Критический путь сохраняет обращение до любого внешнего вызова





Рисунок 3 Критический путь и обратная связь

6 4 Правила модульности

- Каждый модуль имеет package boundary, собственные application services, repository interface и таблицы в своей PostgreSQL schema.
- Запись в таблицы другого модуля запрещена code review и integration test. Чтение для аналитики идёт через materialized views или approved read model.
- Внутренний Python import не считается стабильным контрактом. Стабильны OpenAPI, JSON Schema и event catalog.
- Вынос модуля в сервис сохраняет operation IDs, event names и data ownership. Миграция использует dual write только через outbox, а не на уровне UI.

7 Архитектура данных

Поток данных и обучение



Записи без надёжной даты не участвуют во временной валидации; они остаются в DQ отчёте и аналитике observed time

Рисунок 4 Поток данных от источника к модели

7 1 Канонические сущности

Сущность	Ключ	Назначение	Хранение
appeal	request id	Текущий snapshot обращения	OLTP schema appeals
appeal event	event id	Неизменяемая история статусов и решений	Partitioned append only table
source record	source system plus source request id	Provenance и идемпотентность импорта	integration schema
prediction	recommendation id	Версионированная подсказка модели	triage schema
operator decision	decision id	Подтверждение или исправление	triage schema
incident	incident id	Общая городская проблема	incident schema
incident member	incident id plus request id plus version	История membership решений	incident schema
service definition	service id plus version	Компетенция и required fields	catalog schema
sla policy	policy id plus version	Расчёт due at и эскалации	catalog schema
embedding	object id plus model version	Retrieval representation	pgvector partition
metric result	query hash plus cutoff	Воспроизводимый результат аналитики	analytics cache and object store
outbox	event id	Надёжная доставка внешних команд	integration schema
audit event	audit id	Доступы и изменения	WORM eligible audit storage

7 2 Временная семантика

Дата события используется только вместе с происхождением и качеством. Платформа различает business time и время наблюдения системой. Это особенно важно для архивных файлов, где 37 canonical records не имеют валидной даты и часть полей не содержит timezone.

Поле	Смысл	Правило при отсутствии
occurred at	Когда событие произошло в источнике	Null; не выводить из номера строки
observed at	Когда Pulse 109 получил событие	Всегда заполняется сервером в UTC
source timezone	IANA зона или явный offset	TBD source; quality source tz assumed
time quality	exact source tz assumed date only missing	Обязательно для каждого business timestamp
effective from to	Действие taxonomy service SLA version	Нельзя применять текущую версию к прошлым решениям без миграции
data cutoff	Последняя дата данных в аналитическом ответе	Обязательно показывается пользователю

7 3 Что делать с отсутствующей датой

1. Сохранить исходное значение и parser error code в raw lineage.
2. Установить business timestamp в null и time quality в missing или date only.
3. Не включать запись в temporal train, validation или backtest, если порядок событий нельзя восстановить без утечки.
4. Для операционного списка использовать observed at и явно маркировать источник времени.
5. Для агрегатов создать отдельный ряд Unknown event date. Не распределять записи по дням пропорционально и не подставлять медиану.
6. Исправление допускается только из авторитетного источника; оно создаёт новую versioned record и сохраняет старое значение.

7 4 Слои данных

Слой	Содержимое	Гарантия	Доступ
Raw	Неизменённые файлы, payloads, media, checksums	Immutable and versioned	Ingestion and audit only
Private	PII, full address, voice, raw free text where required	Encrypted and separately keyed	Strict ABAC
Silver	Canonical appeals and lifecycle events	Schema validated and provenance complete	Operational modules
Gold	Approved metrics, training views, forecast series	Versioned definitions and cutoff	Analytics and ML
Quarantine	Rows that fail type, semantics or required fields	Never silently discarded	Data steward

7 5 Data quality gates

Gate	Проверка	Реакция
Schema	Required fields, types, enum, new columns	Reject batch or quarantine rows by policy

Gate	Проверка	Реакция
Identity	Duplicate source IDs and conflicting payload hashes	Idempotent replay or conflict queue
Time	Parse rate, timezone, impossible order	Quality flag and exclusion from temporal metrics
Semantics	Status in channel, mixed column families, unknown codes	Schema drift alert and mapping review
PII	Unexpected identifiers in text, logs or exports	Block downstream publication and alert security
Freshness	Latest observed and occurred times by source	Freshness breach alert; display stale watermark
Coverage	Regions, classes, languages and channels present	Coverage dashboard; no imputed zero

7 6 Синтетические данные

Синтетические записи допустимы для contract tests, UI состояний, редких error paths и нагрузочного тестирования. Они не заменяют отсутствующие 13 регионов, raw text или ground truth и не входят в итоговую held out метрику. Каждый synthetic dataset получает generator version, seed, purpose и признак synthetic. Для редких классов модель может использовать augmentation только после отдельного ablation test на реальном test set.

8 Архитектура машинного обучения

8 1 Задачи и кандидаты

Зафиксированный стек пилота версии 1.1. Модели остаются заменяемыми через единые serving contracts; названия ниже определяют стартовую реализацию, а не необратимую зависимость платформы.

Маршрутизация: XLM RoBERTa base с иерархическими multi label heads, калибровкой confidence и OOD gate.

Поиск и дубликаты: BGE M3 для embeddings, гибридный BM25 и vector retrieval, затем BGE reranker v2 m3; география, время и служба входят как отдельные признаки.

Генерация и речь: Qwen3 8B в четырёхбитном режиме только для черновика и объяснения; Whisper large v3 turbo для транскрипции звонков после получения аудио и согласования обработки.

Персональные данные и прогноз: regex и утверждённые словари дополняются XLM R NER; прогноз нагрузки строится CatBoost или LightGBM и сравнивается с seasonal naive baseline.

Задача	Baseline	Candidate	Основные метрики
Topic and service classification	Character TF IDF plus linear model	XLM RoBERTa base fine tuning with hierarchical multi label heads	Macro F1 Top 3 recall critical recall ECE
Language ID	Rules plus compact classifier	Joint encoder head if it improves slices	F1 by kk ru mixed

Задача	Baseline	Candidate	Основные метрики
Similar resolution retrieval	BM25 or PostgreSQL FTS	BGE M3 fine tuning plus BGE reranker v2 m3	Recall 10 MRR nDCG 10 latency
Duplicate candidates	Text plus exact geo and time rules	Calibrated pair model over text geo time service	Pair precision recall and B cubed
Forecast	Seasonal naive	StatsForecast and LightGBM lag calendar model	WAPE MASE pinball coverage
Anomaly alert	EWMA or count control limit	Forecast residual plus geo semantic incident evidence	Precision recall time to detect alerts per shift
Draft response	Approved templates	Qwen3 8B local four bit with approved RAG and templates	Factual error accept rate edit distance
Natural language analytics	Structured filter UI	Metric ID router and constrained AST; Qwen3 8B may parse intent but cannot execute arbitrary SQL	Exact metric match answer accuracy refusal quality

8 2 Разрешённые признаки

Группа	Можно при первичном приёме	Нельзя как intake feature
Текст	Raw or redacted text available before decision	Operator edited result and final answer
Время	Received time, day, hour, known calendar	Closing date and actual SLA outcome
Канал	Original intake channel	Post resolution communication channel if added later
Гео	Normalized geo known at decision time	Contractor selected after assignment
Каталог	Effective service definitions at received at	Current service name applied retrospectively
История	Prior closed cases retrieved as evidence	Selected service, status, result from the target row

8 3 Обучающий контур

1. Dataset builder читает только approved Gold views и формирует manifest с source IDs, cutoff, feature list, label policy, exclusions, hash и legal basis.
2. Split выполняется по времени. Последние шесть восемь недель каждого региона резервируются для test, если available date quality позволяет.
3. Все snapshots одного source ID, duplicate group и incident cluster остаются в одном split.
4. Leave one region out оценка измеряет перенос. Павлодар не должен определять общий результат из-за 67,3 процента объёма.
5. Calibration set отделён от test. Thresholds выбираются до единственного итогового test evaluation.
6. Candidate сравнивается с baseline по языку, региону, теме, длине, каналу, confidence coverage и OOD.
7. После model card и approval версия идёт в shadow, затем limited canary, затем champion alias. Rollback не требует переобучения.

8 4 Минимальная разметка

Набор	Рабочий минимум	Требование к качеству
Intake	3 000 исходных обращений	Баланс kk ru mixed, редкие и опасные темы; double label части
Retrieval	500 queries by top 20 candidates	Relevance 0 1 2, два эксперта для контрольной доли
Duplicates	1 000 pairs and 100 clusters	Positive и hard negative; human confirmation
NL analytics	100 real management questions	Metric ID, dimensions, filters and expected result
Alerts	Historical episodes and negative windows	Actionability, urgency and acceptable frequency

Это плановый бюджет разметки, а не доказанный статистический минимум. После первых learning curves объём пересматривается. Без исходного текста обязательное fine tuning требование остаётся незакрытым.

8 5 Модельные gates

Компонент	Gate для первого pilot	Дополнительное условие
Classifier	Macro F1 выше TF IDF не менее чем на 10 процентных пунктов	Critical recall не ниже 95 процентов; ECE не выше 0,05; TBD owner
Retrieval	Recall at 10 не ниже 0,85 на judged set	P95 не выше 1 s на representative filters
Duplicates	Suggestion precision не ниже 0,95	Никакого auto merge
Forecast	WAPE лучше seasonal naive минимум на 10 процентов или baseline wins	Публикуются P50 P90 и coverage
Alerts	Precision не ниже 0,70	Не более пяти новых operational alerts за смену по default
NL analytics	Exact metric match не ниже 0,95 на allowlisted set	Unknown questions safely refused
Draft	Zero unsupported factual claims on release test	Operator sends and evidence refs visible

Пороги являются предложением команды и становятся договорными только после согласования с владельцем процесса. Если baseline выигрывает, production использует baseline.

8 6 Serving на двух GPU

Ресурс	Основная роль	Деградация
GPU 0	XLM RoBERTa classifier, BGE M3 embeddings and BGE reranker v2 m3 with bounded batching	ONNX CPU classifier, PostgreSQL FTS and queued embedding refresh
GPU 1	Qwen3 8B four bit and Whisper large v3 turbo on demand; challenger training outside peak	Draft and ASR disabled; GPU 0 remains the operator critical path
CPU	API, rules, address resolver, forecast, exports, lexical retrieval	Core remains functional during GPU outage

Ресурс	Основная роль	Деградация
RAM	Caches, PostgreSQL buffers and model preprocessing	Reduce cache and concurrency, not data correctness

- Для пилота зафиксирован Qwen3 8B в четырёхбитном режиме как кандидат для черновиков и управляемого NLQ. Его включение в production допускается только после проверки лицензии, закрытого казахско-русского теста, VRAM и политики информационной безопасности.
- Quantization принимается после accuracy regression test. Экономия памяти не оправдывает провал редких или казахских классов.
- Triton вводится только если ONNX Runtime не проходит measured concurrency. Один дополнительный runtime не должен появляться ради названия в схеме.

8 7 Мониторинг и переобучение

Сигнал	Порог	Действие
Input drift	PSI or embedding distance above approved band	Investigate by region and channel; no automatic retrain
Unknown taxonomy values	Any new high volume value	Data steward mapping before model use
Confidence shift	Coverage changes beyond approved band	Recalibrate or rollback after review
Human correction	Sustained increase by class or service	Error analysis and targeted labels
Critical recall	Any confirmed critical miss in safety test	Immediate rule review and possible rollback
Latency or errors	SLO burn rate	Scale, degrade optional model or rollback

9 API и интеграции

Полный базовый контракт находится в technical pack openapi.yaml. Он содержит 18 paths и 26 schemas для requests, decisions, incidents, analytics, reports, catalog и operations. Каноническая запись отдельно определена JSON Schema.

9 1 Общие правила API

Правило	Требование
Версия	1.1
Время	RFC 3339 with explicit offset; server stores UTC and source timezone
Encoding	UTF 8; language values kk ru mixed unknown
Identity	UUID inside Pulse; source system plus source ID retained
Idempotency	Required for every write; same key and body returns same result; different body conflicts
Concurrency	Optimistic request version on decisions, assignments and status transitions
Errors	application problem json with stable code and trace ID; no stack traces
Pagination	Cursor based for changing collections; limit bounded

Правило	Требование
Security	Approved OIDC JWT, region and role claims, mTLS or gateway controls where required
Audit	Actor token, purpose, correlation ID and changed fields for sensitive operations

9 2 Внутренний adapter contract

Операция	Direction	Гарантия
create or import request	Source to Pulse	Deduplicate by source system and source request ID
push assignment	Pulse to source	Idempotent by command ID; external ID returned
push status event	Either	Deduplicate by source event ID; preserve business time
list services	Source to Pulse	Effective dates and mapping version
get required fields	Source to Pulse	Schema versioned by service and time
attach evidence	Either	Reference or streamed upload with checksum and malware scan
health and checkpoint	Adapter to operations	Lag, last success, last error and retry state

9 3 Доставка и повтор

1. Core commits domain state and outbox row in one transaction.
2. Worker locks a bounded batch with skip locked, calls the adapter and records attempt metadata.
3. Retryable failures use exponential backoff with jitter. HTTP 429 respects Retry After. Authentication and schema errors are permanent until configuration changes.
4. Consumer deduplicates by event ID or command ID. Delivery is at least once; business effect must be effectively once.
5. After the bounded attempt policy, the message enters dead letter state with operator visibility. Replay creates a new attempt but preserves the original command.

9 4 Status mapping

Canonical state	Allowed previous states	External mapping
new	none	Created or registered
triage	new reopened	Under operator review
assigned	triage assigned	Sent to responsible service
accepted	assigned	Accepted by service
in progress	accepted waiting	Work started
waiting	accepted in progress	Waiting for data or external dependency with reason
resolved	in progress waiting	Result submitted with evidence
closed	resolved	Closure confirmed by policy

Canonical state	Allowed previous states	External mapping
reopened	resolved closed	Citizen or supervisor reopened with reason
cancelled	new triage assigned	Cancelled under an approved reason code

Каждый adapter ведёт явную таблицу source status to canonical status. Unknown source status never maps silently; it enters mapping review while the original code remains stored.

9 5 Казахстанские интеграционные точки

Система или платформа	Роль	Что подтверждено	Что нужно получить
Региональные 109	Systems of execution and channel records	В ТЗ перечислены несколько разных ИС	First target, API, owner, schemas, auth, sandbox
iKOMEK 2.0	Existing city platform	Астана сообщает full lifecycle, SLA, duplicates, analytics and vector knowledge base	Boundary and incremental value for Pulse 109
e Otinish	National appeals workflow	Есть статусы, история и развиваемые AI функции	Legal and technical relationship to 109 incidents
Smart Bridge	Government integration platform	Официально предназначен для упрощения интеграций	Whether mandatory, protocol, onboarding and gateway limits
QazTech	Government platform profile	Provides unified lifecycle standards and platform components	Deployment profile, available services and security controls

10 Безопасность и персональные данные

Безопасность должна пройти согласование владельца данных и информационной безопасности. Этот раздел задаёт минимальные инженерные контроли, но не заменяет правовое заключение, классификацию ИС и отраслевые требования заказчика.

10 1 Классы данных

Класс	Примеры	Разрешённое хранение и использование
Public	Опубликованные агрегаты и справочники	Public UI after disclosure review
Internal	Operational metrics without PII	Authenticated staff by role and region
Confidential	Redacted free text, operator notes, model feedback	Encrypted, purpose limited, audited
Restricted PII	Name, phone, full address, voice, media, identifiers	Private zone, strict ABAC, separate keys, no external LLM
Security	Secrets, tokens, audit evidence, vulnerability reports	Vault or approved secret store, security roles only

10 2 RBAC и ABAC

RBAC задаёт тип полномочия, а ABAC ограничивает регион, организацию, назначенную службу, purpose и classification. Deny by default применяется ко всем новым endpoint, metric, export и dataset.

Объект	Operator	Supervisor	Executor	Analyst	ML owner	Auditor
Assigned appeal	RW	RW	RW own	Aggregate	Redacted sample	R

Объект	Operator	Supervisor	Executor	Analyst	ML owner	Auditor
Restricted PII	R by need	R by need	R own if required	No	No	R by approved audit
Incident membership	Propose	Approve	R	Aggregate	Redacted label	R
Metric query	Limited	Region	Own service	Approved scopes	Quality scopes	R
Model promotion	No	No	No	No	Propose	R
Audit log	Own actions	Region	Own actions	No PII	Model events	Approved full

10 3 Обязательные контроли

Контроль	Реализация	Проверка
Identity	OIDC SSO, MFA for privileged roles, short lived tokens	Role and token expiry tests
Transport	TLS, mTLS or approved gateway for system calls	Automated configuration scan
Encryption	At rest for database, object store and backups; managed keys	Restore test and key rotation evidence
Secrets	No secrets in repo images logs or CI output	Secret scan and runtime mount test
Audit	Read, export, decision, admin, model and policy events	Immutable retention and correlation test
Input safety	Schema limits, attachment type and size, malware scan	Negative and fuzz tests
Prompt security	No arbitrary tools, SQL or untrusted instructions; output schema	Injection red team and allowlist tests
Export	PII masking, row limits, purpose, audit and expiry	Role and data leak tests
Supply chain	Pinned dependencies, SBOM, image signing, vulnerability gate	CI evidence for release artifact
Retention	Policy by data class and legal basis	Deletion and legal hold tests

10 4 Threat model

Угроза	Основной риск	Меры
Excessive operator access	Просмотр чужих регионов или PII	Region scope, purpose, audit, anomaly alerts
Prompt injection in appeal text	LLM пытается вызвать tool or reveal data	Treat text as data, constrained tools, output validation
Model or data poisoning	Feedback changes model quality	Approved labels, provenance, anomaly checks, signed datasets
Adapter replay	Duplicate assignment or status	Idempotency and source event ledger
Export exfiltration	Large PII download	Masking, quotas, approval, watermark metadata, audit
Ransomware or deletion	Loss of operational history	Least privilege, immutable backup, restore drills


Угроза	Основной риск	Меры
Compromised model artifact	Changed weights or code	Registry hash, signed image, admission policy
Silent schema drift	Wrong columns become features	Contract test, quarantine and data steward approval

10 5 Правовая привязка

Республика Казахстан имеет Закон об искусственном интеллекте от 17 ноября 2025 года и действующий Закон о персональных данных и их защите. Для проекта это означает прозрачность участия AI, сохранение человеческого контроля, минимизацию данных, определённую цель обработки, управление сроком хранения и доказуемый доступ. Конкретный legal basis, сроки и допустимый контур передачи остаются TBD владельца данных и юристов.

11 Инфраструктура и развёртывание

Развёртывание в закрытом контуре



Минимальный пилот может работать на одном CPU узле, но production SLO требует устранения одиночных точек отказа

Рисунок 5 Рекомендуемая топология закрытого контура

11 1 Профили среды

Среда	Назначение	Данные	Минимальные условия
local demo	Offline backup for pitch	Synthetic and anonymized frozen snapshot	Docker Compose, local models, no external dependency
development	Daily integration	Synthetic plus approved anonymized samples	CI deploy, developer SSO, disposable database

Среда	Назначение	Данные	Минимальные условия
test	Contract, E2E, load and security	Representative anonymized data	Same images and configuration schema as production
pilot	Shadow or limited real workflow	Approved real data	Network, SSO, audit, backup, monitoring, one adapter
production	Full service	Approved real data for onboarded regions	HA, DR, on call, SIEM, capacity and change approval

11 2 Начальный sizing

Компонент	Pilot baseline	Production direction
CPU application	2 instances each 8 vCPU and 16 to 32 GB RAM	Scale by measured concurrency; separate worker pools
GPU	One node with up to 2 GPUs and preferably at least 24 GB VRAM each	GPU 0 routing and retrieval; GPU 1 Qwen and Whisper, training or hot spare
PostgreSQL	16 vCPU, 64 GB RAM, fast NVMe, monitored backup	Primary plus replica or approved managed HA
Object storage	500 GB initial encrypted capacity	Capacity formula from attachments retention and growth
Cache	Redis optional for locks and short lived cache	HA only if made critical; never source of truth
Network	1 Gbps internal target and approved ingress	Private links and separated backup path

Sizing является стартовой конфигурацией, а не закупочным расчётом. Он пересчитывается после ответа о числе операторов, типе GPU, attachment volume, retention, regional peak и доступности managed database.

11 3 Deployment packaging

- Каждый процесс собирается в reproducible OCI image с pinned digest, non root user, read only filesystem where possible and health probes.
- Docker Compose запускает local demo. Helm chart разворачивает те же images в Kubernetes or OpenShift profile. QazTech profile добавляется через values and adapters, а не fork codebase.
- Database migrations versioned and forward compatible. Destructive migration requires backup, rehearsal and explicit approval.
- Models are mounted by immutable registry version. Service starts only when tokenizer, weights, config and label map hashes match.

11 4 Конфигурация

Тип	Пример	Правило
Public config	Feature flags, endpoint timeouts, UI locale	Versioned and reviewed
Sensitive config	Database URL, OAuth secret, encryption key reference	Approved secret store only
Policy	SLA rules, safety rules, export limits	Versioned, effective dated and approved
Model	Champion alias, thresholds, label map	Registry controlled with rollback
Adapter	Base URL, auth profile, status mapping	Per environment and source; no source secret in code

12 Производительность и надёжность

12 1 Предлагаемые SLO

Путь	Цель	Нагрузка при тесте	Fallback
Create request without ML	p95 under 500 ms	100 RPS sustained and 300 RPS burst	None; critical path
Classification top 3	p95 under 700 ms	Representative kk ru lengths and concurrency	Manual catalog
Similar search	p95 under 1 s	1 million vectors with region topic status filters	Full text search
Operator card	p95 under 1.5 s	500 concurrent sessions proposed	Partial card with stale indicator
Governed NL query	p95 under 5 s	100 approved questions	Structured filter UI
PDF or XLSX report	95 percent under 60 s	Approved representative template	Queued retry
Availability	99.9 percent monthly target	Critical API and manual intake	Planned maintenance excluded by agreement

Нагрузочные значения являются предложенным envelope до получения фактических пиков. Они специально выше среднего потока, но должны быть заменены согласованными цифрами после интервью с владельцем call center.

12 2 Capacity model

Параметр	Обозначение	Формула или вход
Peak intake rate	R peak	TBD from per minute source logs; not annual average
Inference concurrency	C ml	R peak times p99 model latency times safety factor
Annual metadata	S meta	requests per year times average canonical bytes times replicas
Attachments	S media	attachments per request times average size times retention
Vector index	S vec	objects times dimensions times bytes plus index overhead measured
Worker backlog	B	Arrival rate minus service rate across external outage window

12 3 Отказоустойчивость

Отказ	Продолжает работать	Ограничение	Восстановление
One GPU	Core, manual intake, remaining GPU or CPU classifier	Lower ML throughput, draft off	Restart or failover by model priority
All ML	Create, manual route, status, analytics already computed	No recommendation	Queue eligible inference and replay
External IS	Local decision and timeline	Sync pending	Outbox retry and reconciliation
Analytics replica	Operational path	Last approved snapshot	Rebuild read models

Отказ	Продолжает работать	Ограничение	Восстановление
Object storage	Metadata intake with attachment pending if policy allows	No new media or reports	Retry after storage restore
Primary database	None unless automated failover configured	Critical outage	Promote replica under approved runbook

12 4 Backup и disaster recovery

Объект	Предлагаемый RPO	Предлагаемый RTO	Проверка
Operational database	5 minutes	60 minutes	Point in time restore quarterly and before major release
Object storage	15 minutes or versioned object	4 hours	Sample and full restore drills
Model registry	After every approved release	2 hours	Restore champion and rollback aliases
Configuration and policies	Git commit	1 hour	Rebuild environment from signed release
Audit	Near real time	4 hours	Integrity and retention verification

RPO and RTO are proposals. They become binding after the owner classifies business criticality and approves the infrastructure budget.

13 Наблюдаемость и эксплуатация

13 1 Telemetry

Слой	Обязательные сигналы	Запрет
API	Rate, p50 p95 p99, errors by stable code, saturation, trace	Request body and PII in logs
Database	Connections, locks, slow queries, replication lag, storage	Logging full free text parameters
ML	Latency, batch, errors, confidence, OOD, model version, slice quality	Raw text as metric label
Adapter	Lag, attempts, success, retry, dead letter, checkpoint	Secrets or external payload in error text
Data quality	Schema failures, missing rates, freshness, unknown values	Silent coercion
Product	AHT, accept correction, reassign, reopen, alert acknowledgement	Using employee metrics without approved purpose

13 2 Release and CI CD

1. Lint, type and unit tests run on every merge request.
2. Contract tests validate OpenAPI, JSON Schema and each adapter fixture.
3. Data leakage, temporal split and model slice tests run before registry candidate creation.
4. SBOM, secret scan, dependency scan and container scan gate the release artifact.

5. Deployment runs migrations, smoke tests and synthetic transactions. A failed check rolls back the application while preserving forward compatible data.
6. Model and application releases are independent but each records compatible contract versions.

13 3 Runbooks

Runbook	Trigger	First safe action
ML unavailable	Inference error budget burn	Disable optional model and expose manual fallback
Adapter backlog	Lag or dead letter threshold	Pause new deliveries for failing source, preserve local intake
Schema drift	Unknown column or semantic type	Quarantine affected rows and freeze mapping version
PII exposure	Sensitive value in log export or ML payload	Revoke access, preserve evidence, notify security owner
Wrong model	Critical quality regression	Move champion alias to approved prior version
Database saturation	Connection and latency SLO burn	Protect writes, shed optional analytics, inspect locks
Bad SLA policy	Incorrect due dates	Stop new policy version and revert effective mapping

14 Тестирование и приёмка

14 1 Test strategy

Уровень	Что проверяет	Минимальный evidence
Unit	Rules, parsers, state transitions, metric formulas	Deterministic test result
Property and fuzz	Dates, encodings, malformed payloads, idempotency	Seed and failing corpus retained
Contract	OpenAPI, canonical schema, adapter mappings	Replay source fixtures
Integration	Database, outbox, object storage, ML calls	Ephemeral environment result
E2E	Citizen or source to operator to adapter to situation center	Recorded run and trace ID
Model	Held out, temporal, region, language and OOD quality	Model card and dataset manifest
Load	Latency, throughput, saturation, backlog	Raw report and environment profile
Resilience	Dependency failure and recovery	Fault scenario and expected degradation
Security	Auth, access, injection, export and supply chain	Findings and closure evidence
Usability	Operator task time and error recovery	Five or more representative users proposed
Restore	Database, objects, models and config	Measured RPO RTO

14 2 Критические приёмочные сценарии

ID	Сценарий	Ожидаемый результат
AC-01	Duplicate API create	Два одинаковых POST дают один request и одинаковый response identity.
AC-02	Kazakh intake	Оператор получает top 3, confidence и может исправить с reason.
AC-03	Low confidence	Нет auto assignment; manual catalog доступен.
AC-04	Missing date	Record quarantined or accepted with null and quality flag; temporal test excludes it.
AC-05	Schema drift	Новая или сдвинутая колонка не попадает silently в canonical feature.
AC-06	External outage	Decision committed, outbox retries, sync status visible, no loss.
AC-07	Duplicate incident	Two requests remain separate after incident confirmation.
AC-08	Prompt injection	Appeal text cannot access SQL, secrets or another region.
AC-09	Analytics consistency	Dashboard, PDF and XLSX show the same Metric ID and values.
AC-10	Model rollback	Champion switches to prior approved version without data migration.
AC-11	GPU loss	Manual intake continues and fallback state is explicit.
AC-12	Access scope	Operator from one region cannot read another region by changed URL or API call.
AC-13	Reassignment	From, to, actor, reason and timestamp create a misroute label.
AC-14	Stale data	Situation center marks cutoff and does not display missing region as zero.
AC-15	Restore	Approved backup restores within target and passes consistency checks.

14 3 Definition of done

- Code reviewed, tested and merged; no critical or high open security findings.
- Requirement ID links to automated test, demo evidence or signed acceptance record.
- API and event changes are documented and compatible; migrations tested on a copy of representative data.
- Metrics dashboard, alert and runbook exist for the new failure mode.
- User facing text is available in approved Russian and Kazakh locale for the touched flow.
- No direct identifiers appear in logs, ML payloads, analytics cache or non restricted exports.

15 План реализации на один месяц

План исходит из команды минимум из четырёх инженерных потоков. Если людей меньше, score P1 сокращается, но data, integration, security и testing не сворачиваются в последние дни.

Период	Data and ML	Backend and integration	Frontend and product	DevOps QA Security
Дни 1 3	Manifest, schema registry, leakage policy	Core skeleton, database modules, OpenAPI	Operator journey and wireframes	CI, environments, threat model
Дни 4 7	Raw privacy silver pipeline, baselines	Appeals, decisions, audit, outbox	Intake and card	Contract, auth and backup smoke
Дни 8 12	Classifier fine tuning and calibration	Catalog, SLA, first adapter	Top 3 and feedback	Load baseline and observability
Дни 11 16	Embedding tuning, retrieval, judged set	Incident graph and status sync	Similar and duplicate review	Failure injection and access tests
Дни 15 20	Forecast, alerts, governed NLQ	Analytics and report jobs	Situation center	Security scan and restore drill
Дни 19 24	Slice metrics, shadow, model cards	Reconciliation and dead letter	Usability fixes and locales	E2E, performance, runbooks
Дни 25 27	Freeze model and demo data	Freeze contracts and release	Freeze UX and demo	Release candidate and rollback drill
Дни 28 30	Evidence and error analysis	Integration fallback	Rehearsal and backup demo	Final acceptance report

15 1 P0 release scope

Область	В релизе	Условие
Regions	All provided seven visible; one live adapter; second mock adapter	No claim of real 20 region coverage until data arrives
Classifier	Baseline plus one fine tuned candidate	Requires raw text or organizer approved label dataset
Retrieval	Fine tuned embedding plus lexical fallback	Judged set and reproducible training
Duplicates	Candidate suggestions and human confirm	No auto merge
Situation center	Coverage, trends, alert, baseline forecast and governed NLQ	Each result has cutoff and Metric ID
Security	SSO or approved demo identity, RBAC, audit, PII separation	Production identity profile after access
Operations	Monitoring, backup, rollback, runbooks and offline demo	Evidence captured before pitch

15 2 Команда и ответственность

Поток	Основная ответственность	Ежедневный выход
Product lead	Scope, user interviews, acceptance, pitch	Decision log, blockers and demo narrative
Data ML	Pipeline, labels, training, evaluation and serving	DQ report, experiment run and error slices
Backend integration	Core, database, API, adapters and audit	Contract tests and integration trace
Frontend	Operator, situation and admin UX	Usable flow and discovered issues

Поток	Основная ответственность	Ежедневный выход
Platform QA	CI, deployment, observability, security and resilience	Test evidence and release status

15 3 Stop rules

- После дня 20 новая P1 функция не входит в release candidate без замены равного объема и product approval.
- После дня 24 запрещены breaking API and schema changes, кроме исправления критической безопасности или потери данных.
- Демо использует frozen dataset, pinned images and local models. Live integration has a tested replay fallback.
- Ни одна метрика не попадает в pitch без run ID, split description and reproducible artifact.

16 Сопровождение и развитие

16 1 Репозитории и ownership

Репозиторий или каталог	Содержимое	Owner
apps web	Operator, situation and admin clients	Frontend owner
services core	Modular business backend	Backend owner
services inference	Serving endpoints and preprocessors	ML owner
adapters source name	Protocol, mappings and fixtures	Integration owner plus source owner
data contracts	JSON Schema, event catalog, metric definitions	Data steward
ml	Training pipelines, evaluation and model cards	ML owner
infra	Compose, Helm, deployment profiles and dashboards	Platform owner
docs	ADRs, runbooks, security and user guides	Joint ownership

16 2 Change management

Изменение	Нужное действие
New source column	Schema drift review; no automatic feature use
New region	Adapter fixture, mapping, data profile, access scope, shadow metrics
New topic or service	New effective taxonomy version and backward mapping
Model update	Dataset manifest, evaluation, model card, approval, shadow, canary
Metric change	New metric version, backfill decision and dashboard annotation
SLA rule change	Policy version with effective date and owner approval
Breaking API	New major version, dual support window and migration guide

Изменение	Нужное действие
New infrastructure component	ADR, ownership, SLO, backup and security review

16 3 Onboarding нового региона

1. Назначить владельца источника и получить data sharing, API, auth, sandbox and contact matrix.
2. Снять source profile, schema, timezone, status lifecycle, service catalog and attachment rules.
3. Собрать adapter fixture and mapping; run contract, idempotency and round trip tests.
4. Провести data quality and privacy review; set retention and access scope.
5. Запустить shadow analytics and model slices; compare against operator decisions.
6. Enable limited canary and measure product metrics before full rollout.

17 Риски и решения

Риск	Вероятность	Влияние	Мера	Владелец
Нет raw text	Высокая	Критическое	P0 запуск; manual label set; transparent limitation	Product and data owner
Нет 13 регионов	Высокая	Критическое	Coverage UI; adapter kit; no synthetic claim	Organizer and data owner
Нет API sandbox	Высокая	Высокое	Contract first mock and replay; select first source	Integration owner
Target leakage	Высокая	Высокое	Feature availability registry and split audit	ML owner
Провал казахского	Средняя высокая	Высокое	Balanced test, error slices and operator review	ML and language reviewer
False duplicate	Средняя	Высокое	High precision threshold and human confirmation	Incident owner
Wrong NL number	Средняя	Высокое	Metric catalog, constrained AST and provenance	Analytics owner
External outage	Средняя	Высокое	Transactional outbox and offline demo	Platform owner
Unknown GPU	Средняя	Среднее	CPU baseline, ONNX and measured capacity	ML platform owner
Taxonomy change	Высокая	Среднее	Effective dated versions and mapping UI	Data steward
Operational alert fatigue	Средняя	Высокое	Alert budget, acknowledgement and review	Supervisor
Scope expansion	Высокая	Высокое	P0 freeze and stop rules	Product lead

17 1 Принятые ADR

ADR	Решение
ADR 001	Модульное бизнес ядро в одном deployable core; inference, workers and adapters separate
ADR 002	PostgreSQL, PostGIS and pgvector until a representative benchmark proves extraction

ADR	Решение
ADR 003	Human confirmation for routing, priority, duplicate membership and generated reply
ADR 004	Stable canonical contract and isolated adapter per regional source

18 Вопросы заказчику

Ответы фиксируются письменно в decision log. До ответа нельзя считать соответствующий пункт готовым к production.

18 1 Данные и модели

ID	Вопрос	Что блокирует
Q-D-01	Где данные остальных 13 регионов и authoritative manifest всех файлов	Покрытие 20 регионов
Q-D-02	Какой экспорт канонический и как связаны CSV и XLSX	Дедупликация источников
Q-D-03	Где raw text or transcript before operator editing	Classifier and embedding fine tuning
Q-D-04	Какие поля доступны at intake and which appear after execution	Leakage free features
Q-D-05	Есть ли reassign history and correction reasons	Routing labels and misroute metric
Q-D-06	Есть ли duplicate group IDs, confirmed pairs or incidents	Duplicate training and evaluation
Q-D-07	Какие safety categories, priorities and SLA rules are authoritative	Rule engine and due date
Q-D-08	Каков language mix and will there be a closed balanced test	Fair bilingual evaluation
Q-D-09	Разрешены ли open source weights and where may artifacts be stored	Licensing and deployment
Q-D-10	Кто controller and processor, what legal basis and retention apply	Privacy and production approval

18 2 Интеграции и инфраструктура

ID	Вопрос	Что блокирует
Q-I-01	Какая региональная ИС первая, кто owner and vendor	First adapter
Q-I-02	Есть ли sandbox, OpenAPI WSDL events or file protocol	Contract implementation
Q-I-03	Integration must use Smart Bridge, eGov gateway or direct network	Topology and approval
Q-I-04	Каковы auth, mTLS, VPN, PKI, service account and SSO requirements	Security profile
Q-I-05	Rate limits, idempotency, attachment limits, retry and SLA	Reliability design
Q-I-06	Where will it run and what QazTech Kubernetes PostgreSQL S3 services exist	Deployment profile
Q-I-07	Exact GPU models, VRAM, drivers and training versus serving policy	Capacity plan
Q-I-08	Outbound internet, package mirror, image registry and model repository	Reproducible build

ID	Вопрос	Что блокирует
Q-I-09	Required SIEM, vulnerability scan, RPO RTO and on call process	Production sign off

18 3 Процесс и пользователи

Роль	Вопросы
Operator	AHT, repeated entry, hardest fields, reasons for reassign, acceptable confidence UI
Supervisor	Acceptable alerts per shift, escalation actions, staffing process
Executor	Accepted statuses, evidence of completion, reopen and feedback
Analyst	Approved metrics, mandatory PDF and XLSX templates, refresh schedules
Security	Data classes, audit retention, export and external model rules
Citizen	Unclear statuses, repeat contact reasons, required channels and accessibility

19 Итоговые критерии готовности

Gate	Пройден если	Evidence
G0 Scope	P0 frozen, TBD owners named, one integration target selected	Signed scope and decision log
G1 Data	Manifest, schema tests, PII map, quarantine and lineage work	Automated DQ report
G2 Model	Reproducible training, leakage audit, slices, calibration and rollback	Model cards and run IDs
G3 Product	Operator and manager complete E2E with fallbacks	Usability and E2E results
G4 Integration	Idempotency, retries, status sync and owner confirmed	Contract and failure tests
G5 Security	Threat model, RBAC, secrets, audit, retention and export controls	Security acceptance
G6 Reliability	Load, endurance, resilience and restore meet agreed targets	Performance and DR report
G7 Operations	Dashboards, alerts, runbooks, support and change process	Operational readiness review
G8 Evidence	Every pitch number reproduces from a versioned artifact	Evidence index

Решение о запуске

Pilot может выйти в реальный ограниченный контур только после G0 to G7 and written data owner approval. National rollout begins region by region after adapter, privacy, model slice and operational acceptance for each source. Отсутствующий raw text, API или legal basis не переводится в скрытое допущение.

Приложение А API и контракты

Файл	Назначение
technical pack openapi.yaml	18 paths and 26 schemas for application API
technical pack canonical request schema.json	Canonical regional appeal envelope
technical pack event catalog.md	Integration event names, envelope and compatibility
technical pack adr	Architecture decisions and extraction gates

А 1 Пример создания обращения

POST /v1/requests
Idempotency-Key: 9a6e0cc4-4f36-4b7a-bb4e-3c2466d1c8d2
X-Region-Id: ASTANA

```
{
  "source_system": "demo-109",
  "source_request_id": "A-2026-000123",
  "region_id": "ASTANA",
  "received_at": "2026-09-10T17:20:00+05:00",
  "channel": "phone",
  "language": "mixed",
  "text": "[redacted text supplied to the intake service]",
  "location": {"geo_id": "geo:astana:object:12345"},
  "consent_or_legal_basis": "TBD-approved-code"
}
```

А 2 Common event envelope

Field	Required	Meaning
event id	Yes	Global UUID and deduplication key
event type and version	Yes	Stable catalog identity and payload compatibility
occurred at and quality	Yes	Business time or explicit missing quality
observed at	Yes	Platform receive time
correlation and causation	Yes where known	Trace user action and event chain
region id	Yes	Security and routing partition
subject id	Yes	Aggregate identity
data classification	Yes	Controls event routing and retention

Приложение В Метрики

Metric ID	Определение	Нужные поля	Ограничение
requests received	Count distinct request IDs received in period	request id, received at quality, region	Unknown date separated

Metric ID	Определение	Нужные поля	Ограничение
first contact resolution	Requests resolved without transfer or follow up under agreed rule	events, contact link, resolution	Definition TBD per center
misroute rate	Requests with confirmed reassignment due to wrong initial service divided by assigned requests	assignment history and reason	Needs reason quality
SLA compliance	Eligible requests resolved by due at under policy version	policy, due at, resolved at	Do not compare incompatible policies
repeat contact	Same citizen token and issue within approved window	lawful token, topic, geo, time	Bias when channels lack identity
alert precision	Confirmed actionable alerts divided by reviewed alerts	alert decision and outcome	Unreviewed excluded and shown
model coverage	Requests above action threshold divided by eligible requests	confidence, OOD, eligibility	Report with accuracy at coverage
data coverage	Regions or sources with fresh valid records divided by expected onboarded sources	manifest and freshness	Not a citizen service metric

Приложение С Источники

№	Источник	Ссылка или происхождение
1	GovTech Camp Государственные задачи	Предоставленный файл GovTech Camp Гос Задачи
2	GovTech Camp Webinar	Предоставленный файл GovTech Camp Webinar
3	Pulse 109 EDA and research report	Внутренний отчёт команды от 10 сентября 2026 года
4	iKOMEK 2.0 official Astana page	https://www.gov.kz/memleket/entities/astana/press/news/details/1007387?lang=ru
5	Astana 2025 digitalisation results	https://www.gov.kz/memleket/entities/astana/press/news/details/1146701?lang=ru
6	Smart Bridge official overview	https://www.gov.kz/memleket/entities/maidd/activities/7
7	QazTech Platform	https://qaztech.gov.kz/
8	Law of Kazakhstan on Artificial Intelligence	https://adilet.zan.kz/rus/docs/Z2500000230
9	Law of Kazakhstan on Personal Data and Protection	https://adilet.zan.kz/rus/docs/Z1300000094

№	Источник	Ссылка или происхождение
10	Open311 GeoReport v2	https://wiki.open311.org/GeoReport_v2/
11	pgvector official repository	https://github.com/pgvector/pgvector
12	ONNX Runtime transformer optimization	https://onnxruntime.ai/docs/performance/transformers-optimization.html
13	MLflow Model Registry	https://mlflow.org/docs/latest/ml/model-registry
14	XLM R paper	https://arxiv.org/abs/1911.02116
15	BGE M3 paper	https://arxiv.org/abs/2402.03216
16	NVIDIA Triton Inference Server	https://docs.nvidia.com/deeplearning/triton-inference-server/user-guide/docs/index.html
17	Qwen3 8B official model card	https://huggingface.co/Qwen/Qwen3-8B
18	Whisper large v3 turbo official model card	https://huggingface.co/openai/whisper-large-v3-turbo
19	BGE reranker v2 m3 official model card	https://huggingface.co/BAAI/bge-reranker-v2-m3

Приложение D Термины

Термин	Определение
Appeal	Отдельное обращение гражданина с собственным номером, историей and SLA.
Incident	Подтверждённая общая проблема, связывающая несколько appeals without deleting them.
Recommendation	Версионированная AI подсказка before a human decision.
Decision	Подтверждённый человеком topic, service and priority.
Canonical contract	Stable model that isolates regional source schemas from platform modules.
Source payload	Original immutable record or reference received from an external system.
Observed time	Time when Pulse 109 received an event.
Occurred time	Business time when the source says an event happened.
OOD	Input outside the model domain or far from supported training data.
Semantic layer	Approved metric definitions, dimensions, filters and executable query plans.

Термин	Определение
Outbox	Database table written with domain state for reliable later event delivery.
Champion	Approved model version used for production decisions.
Challenger	Candidate evaluated in shadow without replacing champion.

Конец документа